

# DOCUMENTACIÓN DE LOS ALGORITMOS DE PRIORIZACIÓN DE CNVs Y SVs

IMPACT-VUSCan project

Eduarne Urrutia y Estefania Huergo (Navarrabiomed)

12 de agosto de 2026

# Índice

|                                                                         |           |
|-------------------------------------------------------------------------|-----------|
| <b>1. Introducción</b>                                                  | <b>1</b>  |
| <b>2. Archivos de entrada</b>                                           | <b>2</b>  |
| 2.1. Archivos base . . . . .                                            | 2         |
| 2.2. Archivos de los nodos de secuenciación . . . . .                   | 2         |
| <b>3. Priorización de CNVs</b>                                          | <b>5</b>  |
| 3.1. Descripción del proceso . . . . .                                  | 5         |
| 3.2. Implementación de los scripts . . . . .                            | 11        |
| <b>4. Priorización de SVs</b>                                           | <b>14</b> |
| 4.1. Descripción del proceso . . . . .                                  | 14        |
| 4.2. Implementación de los scripts . . . . .                            | 15        |
| <b>Nota sobre genotipo y número de copias</b>                           | <b>17</b> |
| <b>5. Arquitectura del flujo</b>                                        | <b>18</b> |
| 5.1. Script principal (orquestador) . . . . .                           | 18        |
| 5.2. Scripts llamados por el orquestador . . . . .                      | 18        |
| <b>6. Requisitos y dependencias</b>                                     | <b>18</b> |
| 6.1. Sistema . . . . .                                                  | 18        |
| 6.2. Entornos Conda . . . . .                                           | 18        |
| 6.3. Dependencias de rutas . . . . .                                    | 18        |
| <b>7. Manual de ejecución</b>                                           | <b>19</b> |
| 7.1. Preparación del entorno de trabajo (solo la primera vez) . . . . . | 19        |
| 7.2. Preparación de los archivos de una familia . . . . .               | 20        |
| 7.3. Uso del orquestador . . . . .                                      | 21        |
| 7.4. Rutas de trabajo . . . . .                                         | 21        |
| 7.5. Flujo completo por pasos . . . . .                                 | 21        |
| <b>Anexo A. Archivos generados y estructura de salida</b>               | <b>24</b> |
| A.1. Estructura de carpetas . . . . .                                   | 24        |
| A.2. Archivos de entrada . . . . .                                      | 24        |
| A.3. Archivos generados . . . . .                                       | 24        |

# 1. Introducción

En este documento se describen de forma detallada los algoritmos de anotación y priorización de *Copy Number Variations* (CNVs) y *Structural Variants* (SVs) desarrollados en el marco del proyecto IMPaCT-VUSCan. Estos algoritmos están diseñados para el análisis de familias con sospecha de cáncer hereditario, con el objetivo de facilitar la priorización de variantes y su interpretación clínica para ayudar en el diagnóstico.

El análisis se realiza sobre datos de secuenciación del genoma completo (WGS) obtenidos a partir de muestras de sangre. Cuando se dispone de muestras tumorales, estas se analizan mediante secuenciación del exoma completo (WES) y se incorporan para complementar el análisis de germinal.

La priorización de variantes se basa en una serie de filtros y anotaciones funcionales desarrolladas específicamente para el análisis de datos genómicos familiares. Las variantes se anotan con información de frecuencia poblacional, genes asociados a cáncer y funciones proteicas relevantes, entre otras. También se evalúa la presencia de cada variante en el probando y en el resto de los miembros de la familia para determinar segregación o herencia compartida.

Los pasos principales de los algoritmos son: (1) preprocesamiento, (2) priorización y (3) generación del informe. Sin embargo, cada uno tiene sus particularidades debido a las diferencias en los archivos de entrada, las herramientas empleadas y las anotaciones específicas de cada tipo de variante. Además, el informe final incorpora información sobre el solapamiento entre CNVs y SVs.

Las muestras proceden de 3 nodos de secuenciación (CNAG, FPGMX y NASERTIC). Cada nodo utiliza diferentes herramientas de detección y archivos en formatos específicos. En el paso de preprocesamiento, estos archivos se adaptan a un formato común para su posterior análisis.

La ejecución de los algoritmos está coordinada por el script `run_family_cnv_sv.sh`, que actúa como el orquestador principal del análisis de las familias. Su objetivo es automatizar y estandarizar el procesamiento completo de CNVs y SVs mediante una única ejecución reproducible.

Para cada familia, el orquestador realiza las siguientes tareas:

1. Anotación de los archivos de somático de entrada con AnnotSV cuando es necesario.
2. Ejecución completa del algoritmo de priorización de CNVs.
3. Ejecución completa del algoritmo de priorización de SVs.

Además, el orquestador incorpora funcionalidades adicionales para la automatización y el seguimiento del proceso:

- Procesamiento de múltiples familias en paralelo.
- Registro de la ejecución mediante archivos log que documentan el análisis de cada familia y el seguimiento del estado global.
- Traslado de la carpeta de cada familia procesada a la carpeta PENDIENTES\_SUBIR/ al finalizar correctamente.

## 2. Archivos de entrada

### 2.1. Archivos base

- Archivo PED con el árbol genealógico para cada familia: <FAMILY\_ID>.ped (carpeta de la familia correspondiente)
- Archivo con información de muestras-fenotipo de todas las familias, que incluye la correspondencia entre los IDs del proyecto (*IMPACT*) y los IDs internos del nodo CNAG: *muestras\_fenotipo.txt* (carpeta del proyecto)
- Archivos para anotar variantes:
  - Lista de 367 genes asociados con cáncer hereditario: *lista\_CH\_genes.txt* (carpeta *cancer\_genes/*)
  - Genes asociados con cáncer de la base de datos COSMIC: *tsg\_og.tsv* (carpeta *cancer\_genes/*)
  - gnomAD: *gnomad.v4.1.cnv.non\_neuro\_controls\_filtered.tsv* (CNVs) y *gnomad.v4.1.sv.non\_neuro\_controls\_final.tsv* (SVs) (carpeta *gnomAD/*)
  - Funciones de Uniprot: *uniprot.txt* (carpeta *pathway\_annotation\_db/*)
  - Rutas de KEGG: *kegg\_pathways.tsv* (carpeta *pathway\_annotation\_db/*)
  - Rutas de Reactome: *Gene2Reactome.txt* (carpeta *pathway\_annotation\_db/*)
  - Frecuencia interna de la cohorte IMPACT-Genómica: *IMPACT\_exact\_counts\_5kbp.tsv* (carpeta *cohort\_freq/*)
- Glosarios para los informes Excel: *glosario\_cnv.xlsx* (CNVs) y *glosario\_sv.xlsx* (SVs) (carpeta *glosarios/*)

Además de estos archivos, la anotación de genes de la base de datos OMIM no requiere un archivo adicional, ya que se incorpora directamente en los archivos de entrada anotados con AnnotSV por cada nodo de secuenciación (véase sección 2.2).

### 2.2. Archivos de los nodos de secuenciación

Según el nodo de secuenciación, el software utilizado para generar los archivos es diferente y el formato de los archivos también. Estos son los archivos que entrega cada uno para cada tipo de muestra con las variantes anotadas con AnnotSV salvo que se indique lo contrario (información adicional en Anexo A):

- **CNVs**
  - **Muestras de ADN germinal**
    - CNAG: Dos archivos que contienen CNVs detectadas en las ventanas de 20,000 bp y 5,000 bp.
      - IMPACT-Genómica: *\*CNV.fixed.tsv* (ventana 20 kbp) y *\*CNV.tsv* (ventana de 5 kbp).
      - VUSCan: *\*fixed.tab.gz* y *\*20000.CNVs.p.value.annotated.IntFreq.tab.gz* (ventana de 20 kbp), y *\*5000.CNVs.p.value.annotated.tsv* y *\*5000.CNVs.p.value.annotated.IntFreq.tab.gz* (ventana de 5 kbp).
    - FPGMX: Dos archivos que contienen CNVs y SVs, *\*split\_sv.full.tab.gz* ('full') y *\*split\_sv.split.tab.gz* ('split').
    - NASERTIC: Un único archivo *\*.tab* (IMPACT-Genómica) o *\*CNVs.annotated.updated.tsv* (VUSCan).
  - **Muestras de ADN somático**
    - CNAG:
      - Tumor Only: *\*TumorOnly.ann.tag.tsv*
      - Tumor vs Normal: *\*Tumor\_vs\_Normal.ann.tag.tsv*

- Tumor vs PON: \*Tumor\_vs\_Baseline.ann.tag.tsv
- FPGMX:
  - Tumor Only: \*\_DTO\_.nonref.cnv.vcf.gz (sin anotar; el *pipeline* genera el archivo \*\_DTO\_.nonref.cnv.filtered\_annotated.tsv.gz filtrado por 'PASS' y anotado).
  - Tumor vs Normal: con patrón \_DTN\_ y puede estar anotado (TSV) o no (VCF).
  - Tumor vs PON: con patrón \_D\_ y puede estar anotado (TSV) o no (VCF). Para VUSCan algunas muestras de tumor pueden tener una 'L' adicional en el patrón (LDTO, LDTN o LD, respectivamente).
- NASERTIC:
  - Tumor Only: \*CNVs.annotated.tsv (IMPaCT-Genómica) o \*4impact.cnv.vcf.gz (VUSCan; modificado a \*4impact-{xx}.cnv.to.vcf; sin anotar; el *pipeline* genera el archivo \*CNVs.TO.filtered\_annotated.tsv.gz filtrado por 'PASS' y anotado).
  - Tumor vs Normal: no hay para IMPaCT-Genómica; \*CNVs.annotated.tsv para VUSCan (modificado a \*.CNVs.TN.annotated.tsv y comprimido a .gz al ejecutar el *pipeline*).
  - Tumor vs PON: \*.CNVs.PON.annotated.tsv (IMPaCT-Genómica) o \*.cnv.vcf (VUSCan; modificado a \*.cnv.pon.vcf; sin anotar; el *pipeline* genera el archivo \*CNVs.PON.filtered\_annotated.tsv.gz filtrado por 'PASS' y anotado)
- SVs
  - **Muestras de ADN germinal**
    - CNAG: \*.SV.fixed.tsv
    - FPGMX: Dos archivos que contienen CNVs y SVs, \*split\_sv.full.tab.gz ('full') y \*split\_sv.split.tab.gz ('split').
    - NASERTIC: \*.SVs.annotated.tab para IMPaCT-Genómica y \*.SVs.annotated.updated.tsv para VUSCan.
  - **Muestras de ADN somático**
    - CNAG:
      - Tumor Only: \*.tumor\_sv.annotated.CandidateGenes.tsv
      - Tumor vs Normal: \*.somatic\_sv.annotated.CandidateGenes.tsv
    - FPGMX:
      - Tumor vs PON: \*\_D\_sv.annotated.tsv.gz
      - Tumor vs Normal: \*\_DTN\_sv.annotated.tsv.gz
      - Tumor Only: \*\_DTO\_.sv.vcf.gz (sin anotar; el *pipeline* genera \*\_DTO\_.sv.filtered\_annotated.tsv.gz, filtrado por 'PASS' y anotado).
    - NASERTIC:
      - Tumor Only: \*.SVs.TO.annotated.PASSfiltered.tsv.gz (IMPaCT-Genómica) o \*.sv.vcf (VUSCan; modificado a \*.sv.to.vcf; sin anotar; el *pipeline* genera el archivo \*SVs.TO.filtered\_annotated.tsv.gz filtrado por 'PASS' y anotado).
      - Tumor vs Normal: \*.TN.annotated.tsv (IMPaCT-Genómica) o \*.SVs.annotated.tsv (VUSCan; modificado a \*.SVs.TN.annotated.tsv).

En la siguiente tabla se recoge un resumen de los archivos proporcionados por cada nodo para CNVs y SVs.

Cuadro 1: Resumen de los archivos proporcionados por cada nodo para CNVs y SVs.

| Nodo     | Variante    | Tipo | Software        | Archivos                                            |
|----------|-------------|------|-----------------|-----------------------------------------------------|
| CNAG     | CNV         | WGS  | Control-FREEC 7 | Dos archivos (5 k y 20 kbp)                         |
|          | SCNA        | WES  | CNVkit          | Tumor Only; Tumor vs Normal; Tumor vs PON           |
|          | SV          | WGS  | MANTA           | Un archivo                                          |
|          | SV somático | WES  | MANTA           | Tumor Only; Tumor vs Normal                         |
| FPGMX    | CNV / SV    | WGS  | DRAGEN          | Archivos con CNVs y SVs ('full'/'split' separado)   |
|          | SCNA        | WES  | DRAGEN          | Tumor Only; Tumor vs Normal; Tumor vs PON           |
|          | SV somático | WES  | DRAGEN          | Tumor Only; Tumor vs Normal; Tumor vs PON           |
| NASERTIC | CNV         | WGS  | DRAGEN          | Un archivo                                          |
|          | SCNA        | WES  | DRAGEN          | Tumor Only*; Tumor vs Normal (VUSCan); Tumor vs PON |
|          | SV          | WGS  | DRAGEN          | Un archivo                                          |
|          | SV somático | WES  | DRAGEN          | Tumor Only*; Tumor vs Normal                        |

*Autonormalización de DRAGEN para Tumor Only. Para Tumor vs Normal y Tumor vs PON, se utiliza la muestra pareada de sangre y un pool de normales no parafinadas, respectivamente.*

**Nota:** Los nodos de secuenciación FPGMX y NASERTIC usan la herramienta DRAGEN para la detección de CNVs y SVs, mientras que CNAG utiliza Control-FREEC y MANTA. Sin embargo, FPGMX y NASERTIC además de no usar la misma versión de DRAGEN, hay que tener en cuenta que NASERTIC elimina todas las CNVs con un tamaño menor a 10 kbp antes de entregar los archivos, mientras que FPGMX no aplica ningún filtro de tamaño, lo que genera diferencias en los resultados de detección de variantes.

Retos identificados:

- En general, no hay comparación entre nodos.
- La información de somático debe ser interpretada con precaución.
- Tumor vs Normal: Se compara WES frente a WGS. Además, para las muestras de IMPaCT-Genómica de NASERTIC no hay este tipo de archivos de CNVs somáticas.
- Tumor vs PON: Falta de un panel de normales adecuado, ya que se utiliza un *pool* de muestras no parafinadas.

### 3. Priorización de CNVs

#### 3.1. Descripción del proceso

El proceso de priorización de CNVs consiste en tres pasos principales:

1. Preprocesamiento
2. Priorización
3. Generación del informe

##### Paso 1. Preprocesamiento

En el primer paso, se realiza el parseo y filtrado de los archivos de entrada proporcionados por los nodos de secuenciación. Se tiene en cuenta que estos archivos de entrada difieren entre nodos y se adaptan a una estructura común para su posterior análisis.

Las CNVs germinales, anotadas con AnnotSV por los nodos, se filtran de acuerdo a los siguientes criterios:

- Calidad mínima: se eliminan variantes con una calidad QUAL inferior a 30. A las muestras de CNAG no se aplica este filtro, ya que esta información no se proporciona.
- Calidad por FILTER: se conservan variantes con valor 'PASS'. Para FPGMX, los archivos no incluyen este campo porque las variantes se entregan filtradas.
- Frecuencia interna exacta: se eliminan variantes con un valor superior a 10 frecuencia interna (Illumina.exact.counts para CNAG e Illumina\_DRAGEN.exact.counts para FPGMX y NASERTIC).
- Selección de CNVs en FPGMX: dado que un mismo archivo contiene CNVs y SVs, se seleccionan las variantes cuyo campo 'SV\_type\_original' corresponde a 'GAIN' o 'LOSS'.

Los filtros se aplican sobre las CNVs 'full' y, cuando una pasa los filtros, se seleccionan también las CNVs 'split' asociadas.

Posteriormente, en las muestras de CNAG se combinan las CNVs únicas de los dos archivos proporcionados (ventanas de 5,000 y 20,000 bp). Para ello, las CNVs detectadas en la ventana de 5 kbp se añaden a las de 20 kbp, eliminando solapamientos recíprocos ( $\geq 70\%$ ) para evitar duplicados. El campo 'CNV\_window' indica la ventana de detección para cada CNV.

Para CNAG, las variantes que no se encuentran en la cohorte referencia usada para calcular las frecuencias internas (exact, similar y other), se codifican como '#' o vacío, por lo que se transforman estos valores a 0. Además, dado que CNAG calcula la frecuencia interna usando muestras de la ventana de 20 kbp como referencia, se añade una frecuencia adicional para la ventana de 5 kbp, calculada con las 186 muestras de la cohorte de IMPaCT-Genómica (campo 'IMPaCT exact counts (5 kbp)').

Cuando hay archivos de somático, las CNVs se filtran por calidad (FILTER = 'PASS' y  $QUAL \geq 30$ ) y se anotan con AnnotSV si no lo están. Excepto para CNAG que da todos los archivos anotados y ya aplica el filtro 'PASS' y no proporciona el campo 'QUAL', por lo que no se aplica ningún filtro adicional.

##### Paso 2. Priorización

Las CNVs germinales, se priorizan mediante dos herramientas basadas en los criterios del ACMG (American College of Medical Genetics and Genomics) y ClinGen (Clinical Genome Resource) para CNVs (Riggs et al., 2019): AnnotSV y ClassifyCNV. Los criterios implementados por ambas herramientas se describen en las Tablas 2 y 3 para CNVs de pérdida y de ganancia, respectivamente.

Dado que AnnotSV y ClassifyCNV no emplean exactamente los mismos criterios ni las mismas bases de datos, se mantienen ambas puntuaciones por separado. El campo 'Discrepancies' recoge los criterios que puntúan de forma diferente entre ambas herramientas para cada CNV.

Cuadro 2: Implementación de los criterios de ACMG/ClinGen para CNVs de pérdida. Abreviaturas: ACMG = American College of Medical Genetics and Genomics; CNV = Copy Number Variation; HI = haploinsuficiencia; TS = triplosensibilidad; LOF = pérdida de función.

| Criterio                                                                                                                                                                                                                                                                                                                | Puntos              |             |         | Fuentes                                                            |                                                              | Evaluación |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------|-------------|---------|--------------------------------------------------------------------|--------------------------------------------------------------|------------|
|                                                                                                                                                                                                                                                                                                                         | ACMG/ClinGen        | ClassifyCNV | AnnotSV | ClassifyCNV                                                        | AnnotSV                                                      |            |
| Sección 1: Evaluación inicial del contenido genómico                                                                                                                                                                                                                                                                    |                     |             |         |                                                                    |                                                              |            |
| 1A. Contiene elementos codificadores de proteínas u otros elementos conocidos importantes funcionalmente                                                                                                                                                                                                                | 0                   | 0           | 0       | RefGene, FANTOM5 Enhancers, Ensembl regulatory build               | RefSeq, ENSEMBL, EnhancerAtlas 2.0 (Consultar documentación) | Si         |
| 1B. No contiene elementos codificadores ni elementos funcionales conocidos                                                                                                                                                                                                                                              | -0.6                | -0.6        | -0.6    | RefGene, FANTOM5 Enhancers, Ensembl regulatory build               | RefSeq, ENSEMBL, EnhancerAtlas 2.0 (Consultar documentación) | Si         |
| Sección 2: Solapamiento con genes/regiones de HI o establecida/predicha o benignos establecidos                                                                                                                                                                                                                         |                     |             |         |                                                                    |                                                              |            |
| 2A. Solapamiento completo de gen/región genómica HI establecido                                                                                                                                                                                                                                                         | 1                   | 1           | 1       | ClinGen, HI, and TS genes and curated regions                      |                                                              | Si         |
| 2B. Solapamiento parcial de una región genómica HI establecida<br>- La CNV NO contiene el gen causante o la región crítica para esta región HI O<br>- No está claro si el gen causante o la región crítica está afectada O<br>- No se ha establecido ningún gen causal específico o región crítica para esta región HI. | 0                   | 0           | 0       | ClinGen HI and TS genes and curated regions                        |                                                              | Si         |
| 2C. Solapamiento parcial con el extremo 5’ de un gen HI / mórbido establecido (extremo 3’ no implicado)...                                                                                                                                                                                                              |                     |             |         | refGene gene features, ClinGen HI and TS genes and curated regions |                                                              |            |
| 2C-1. ... y la secuencia codificante está implicada                                                                                                                                                                                                                                                                     | 0.90<br>(0.45-1.00) | 0.90        | 0.90    |                                                                    |                                                              | Si         |
| 2C-2. ... y sólo está implicada la 5’ UTR                                                                                                                                                                                                                                                                               | 0 (0–0.45)          | 0           | 0       |                                                                    |                                                              | Si         |

|                                                                                                              |                     |      |      |                                                                                         |                                                                                                                                |
|--------------------------------------------------------------------------------------------------------------|---------------------|------|------|-----------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------|
| 2D. Solapamiento parcial con el extremo 3' de un gen HI mórbido establecido (extremo no implicado) ...       |                     |      |      | refGene<br>gene<br>features,<br>ClinGen HI<br>and TS<br>genes and<br>curated<br>regions |                                                                                                                                |
| 2D-1. ... y solo está implicada la UTR 3'                                                                    | 0                   | 0    | 0    |                                                                                         | Sí                                                                                                                             |
| 2D-2. ... y solo está implicado el último exón. Se han descrito variantes patogénicas en este exón.          | 0.90<br>(0.45-0.90) | 0.30 | 0.90 |                                                                                         | AnnotSV:<br>Sí<br>ClassifyCNV:<br>Parcialmente<br>(0.30<br>puntos<br>existan o<br>no<br>variantes<br>patogénicas<br>descritas) |
| 2D-3. ... y sólo el último exón está implicado. No se han descrito otras variantes patogénicas en este exón. | 0.30 (0-0.45)       | 0.30 | 0.45 |                                                                                         | AnnotSV:<br>Sí<br>ClassifyCNV:<br>Parcialmente<br>(0.30<br>puntos<br>existan o<br>no<br>variantes<br>patogénicas<br>descritas) |
| 2D-4. ... e incluye otros exones además del último exón. Se espera NMD.                                      | 0.90<br>(0.45-1.00) | 0.90 | 0.90 |                                                                                         | Sí                                                                                                                             |

|                                                                                                                                                                       |                              |                                                                   |                                                   |                                             |                                                                                                                                                                                                                                                                                                    |
|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------|-------------------------------------------------------------------|---------------------------------------------------|---------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 2E. Ambos breakpoints están dentro del mismo gen (CNV intragénica) ...                                                                                                | 2E-1<br>2E-2<br>2E-3<br>2E-4 | - PVS1 = 0.90<br>- N/A = Sin puntos, pero continuar la evaluación | 2E-1: 0.9<br>2E-2: 0.45<br>2E-3: 0.3<br>2E-4: 0.2 |                                             | AnnotSV:<br>Sí<br>ClassifyCNV:<br>Parcialmente.<br>Se asignan puntos a las variantes intragénicas en transcritos biológicamente relevantes que alteran el marco de lectura y se prevé que provoquen una desintegración sin sentido. No se asignan puntos a otros tipos de deleciones intragénicas. |
| 2F. Completamente contenida dentro de una región CNV benigna.                                                                                                         | -1                           | -1                                                                | -1                                                | ClinGen HI and TS genes and curated regions | Sí                                                                                                                                                                                                                                                                                                 |
| 2G. Se solapa con una CNV benigna, pero incluye material genómico adicional.                                                                                          | 0                            | 0                                                                 | 0                                                 | ClinGen HI and TS genes and curated regions | Sí                                                                                                                                                                                                                                                                                                 |
| 2H. Dos o más predictores HI sugieren que AL MENOS UN gen del intervalo es HI.                                                                                        | 0.15                         | 0.15                                                              | 0.15                                              | DECIPHER, ExAC pLI scores                   | Sí                                                                                                                                                                                                                                                                                                 |
| <b>Sección 3: Evaluación del número de genes</b>                                                                                                                      |                              |                                                                   |                                                   |                                             |                                                                                                                                                                                                                                                                                                    |
| 3A. 0-24 genes.                                                                                                                                                       | 0                            | 0                                                                 | 0                                                 | RefGene                                     | Sí                                                                                                                                                                                                                                                                                                 |
| 3B. 25-34 genes.                                                                                                                                                      | 0.45                         | 0.45                                                              | 0.45                                              | RefGene                                     | Sí                                                                                                                                                                                                                                                                                                 |
| 3C. 35+ genes.                                                                                                                                                        | 0.90                         | 0.90                                                              | 0.90                                              | RefGene                                     | Sí                                                                                                                                                                                                                                                                                                 |
| <b>Sección 4: Evaluación detallada del contenido genómico utilizando casos de la literatura publicada, bases de datos públicas y/o datos internos del laboratorio</b> |                              |                                                                   |                                                   |                                             |                                                                                                                                                                                                                                                                                                    |
| 4A-4N.                                                                                                                                                                | -                            | -                                                                 | -                                                 | -                                           | -                                                                                                                                                                                                                                                                                                  |
| 4O. Solapamiento con variación común en la población.                                                                                                                 | -1 (0 - -1)                  | -1                                                                | -1                                                | DGV Gold Standard Variants                  | gnomAD, ClinVar, ClinGen, DDD, dbVar<br>Sí                                                                                                                                                                                                                                                         |

Cuadro 3: Implementación de los criterios de ACMG/ClinGen para CNVs de ganancia. Abreviaturas: ACMG = American College of Medical Genetics and Genomics; CNV = Copy Number Variation; HI = haploinsuficiencia; TS = triplosensibilidad; LOF = pérdida de función.

| Criterio                                                                                                                                                                                                                                                                                                     | Puntos       |             |         | Fuentes                                              |                                                              | Evaluación |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------|-------------|---------|------------------------------------------------------|--------------------------------------------------------------|------------|
|                                                                                                                                                                                                                                                                                                              | ACMG/ClinGen | ClassifyCNV | AnnotSV | ClassifyCNV                                          | AnnotSV                                                      |            |
| Sección 1: Evaluación inicial del contenido genómico                                                                                                                                                                                                                                                         |              |             |         |                                                      |                                                              |            |
| 1A. Contiene elementos codificadores de proteínas u otros elementos funcionalmente importantes.                                                                                                                                                                                                              | 0            | 0           | 0       | RefGene, FANTOM5 Enhancers, Ensembl regulatory build | RefSeq, ENSEMBL, EnhancerAtlas 2.0. Consultar documentación. | Sí         |
| 1B. NO contiene elementos codificadores de proteínas ni otros elementos funcionales conocidos.                                                                                                                                                                                                               | -0.6         | -0.6        | -0.6    | RefGene, FANTOM5 Enhancers, Ensembl regulatory build |                                                              | Sí         |
| Sección 2: Solapamiento con genes/regiones genómicas de HI establecida/predicha o benignos establecidos                                                                                                                                                                                                      |              |             |         |                                                      |                                                              |            |
| 2A. Superposición completa; el gen TS o la región crítica mínima está totalmente contenida dentro de la CNV.                                                                                                                                                                                                 | 1            | 1           | 1       | ClinGen HI and TS genes and curated regions          |                                                              | Sí         |
| 2B. Solapamiento parcial de una región genómica TS:<br>- La CNV NO contiene el gen causante o la región crítica para esta región TS O<br>- No está claro si el gen causante o la región crítica está afectada O<br>- No se ha establecido ningún gen causal específico o región crítica para esta región TS. | 0            | 0           | 0       | ClinGen HI and TS genes and curated regions          |                                                              | Sí         |
| 2C. Idéntico en contenido génico a CNV de ganancia benigna.                                                                                                                                                                                                                                                  | -1           | -1          | -1      | ClinGen HI and TS genes and curated regions          |                                                              | Sí         |
| 2D. Menor que la CNV de ganancia benigna; los breakpoints no interrumpen genes codificantes.                                                                                                                                                                                                                 | -1           | -1          | -1      | RefGene, ClinGen HI and TS genes and curated regions |                                                              | Sí         |

|                                                                                                                                                                                                                                                                                                                                          |                      |                                     |      |                                                                             |                                        |
|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------|-------------------------------------|------|-----------------------------------------------------------------------------|----------------------------------------|
| 2E. Menor que la CNV de ganancia benigna; el/los breakpoints interrumpe(n) potencialmente un gen codificante.                                                                                                                                                                                                                            | 0                    | 0                                   | 0    | RefGene, refGene gene features, ClinGen HI and TS genes and curated regions | Sí                                     |
| 2F. Mayor que la CNV de ganancia benigna, no incluye genes codificantes adicionales.                                                                                                                                                                                                                                                     | -1 (0 - -1.00)       | -1                                  | -1   | RefGene, ClinGen HI and TS genes and curated regions                        | Sí                                     |
| 2G. Se solapa con una CNV benigna, pero incluye material genómico adicional.                                                                                                                                                                                                                                                             | 0                    | 0                                   | 0    | RefGene, ClinGen HI and TS genes and curated regions                        | Sí                                     |
| 2H. Gen HI totalmente contenido en la CNV.                                                                                                                                                                                                                                                                                               | 0                    | 0                                   | 0    | ClinGen HI and TS genes and curated regions                                 | Sí                                     |
| 2I. Ambos breakpoints se encuentran en el mismo gen (posible LOF):<br>2I-1. ... e interrumpe el marco de lectura.<br>2I-2. ... y el fenotipo del paciente es altamente específico y consistente con lo descrito para este gen HI/mórbido.<br>2I-3. ... y el fenotipo del paciente no concuerda con lo descrito para este gen HI/mórbido. | 2I-1<br>2I-2<br>2I-3 | 2I-1: 0.45<br>2I-2: 0.45<br>2I-3: 0 |      | AnnotSV:<br>Sí.<br>ClassifyCNV:<br>No.                                      |                                        |
| 2J. Un breakpoint está dentro de un gen HI, y el fenotipo del paciente es inconsistente o desconocido.                                                                                                                                                                                                                                   | 0                    | 0                                   | 0    |                                                                             | Sí                                     |
| 2K. Un breakpoint está dentro de un gen HI, y el fenotipo del paciente es altamente específico y consistente.<br>ClassifyCNV: No.                                                                                                                                                                                                        | 0.45                 | -                                   | 0.45 |                                                                             | AnnotSV:<br>Sí.<br>ClassifyCNV:<br>No. |
| 2L. Uno o ambos puntos de rotura están dentro de gen(es) sin importancia clínica.                                                                                                                                                                                                                                                        | 0                    | 0                                   | 0    |                                                                             | Sí                                     |
| <b>Sección 3: Evaluación del número de genes</b>                                                                                                                                                                                                                                                                                         |                      |                                     |      |                                                                             |                                        |
| 3A. 0-34 genes                                                                                                                                                                                                                                                                                                                           | 0                    | 0                                   | 0    | RefGene                                                                     | Sí                                     |

|                                                                                                                                                                       |             |      |      |                                  |    |
|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------|------|------|----------------------------------|----|
| 3B. 35-49 genes                                                                                                                                                       | 0.45        | 0.45 | 0.45 | RefGene                          | Sí |
| 3C. 50+ genes                                                                                                                                                         | 0.9         | 0.9  | 0.9  | RefGene                          | Sí |
| <b>Sección 4: Evaluación detallada del contenido genómico utilizando casos de la literatura publicada, bases de datos públicas y/o datos internos del laboratorio</b> |             |      |      |                                  |    |
| 4A-4N                                                                                                                                                                 | -           | -    | -    | -                                | No |
| 4O. Solapamiento con variación común en la población.                                                                                                                 | -1 (0 - -1) | -1   |      | DGV Gold<br>Standard<br>Variants | Sí |

Además de la clasificación, se anotan las variantes del probando y de los familiares no presentes en el probando con la siguiente información:

- CNVs compartidas entre probando y/o familiares (solapamiento recíproco  $\geq 70\%$ ), combinando las únicas de familiares.
- Genes afectados: asociación con cáncer (cáncer hereditario y base de datos COSMIC), sensibilidad a dosis génica y participación en rutas/funciones (Uniprot, KEGG y Reactome).
- Frecuencia poblacional usando la base de datos gnomAD (solapamiento recíproco  $\geq 70\%$ ).
- Presencia en somático de las CNVs del probando (solapamiento recíproco  $\geq 70\%$ ).
- Solapamiento con SVs detectadas en el probando (solapamiento recíproco  $\geq 70\%$ ).

### Paso 3. Generación del informe

Finalmente, se genera un informe en formato Excel con el nombre '>ID\_familia>\_prioritized\_CNVs.xlsx' con toda la información de los pasos anteriores y que incluye las siguientes hojas:

- Proband: CNVs del probando ordenadas por puntuación de AnnotSV, después por puntuación de ClassifyCNV y, por último, por longitud. Se recoge coordenadas genómicas y tipo de CNV, clasificaciones de ClassifyCNV y AnnotSV con sus posibles discrepancias, anotación de los genes afectados (incluyendo asociación a cáncer hereditario, COSMIC, sensibilidad a la dosis génica, OMIM y Uniprot, KEGG y Reactome), información familiar (genotipo, estado, sexo y breakpoints), presencia en tumor, frecuencia interna, solapamiento con gnomAD y solapamiento con SVs.
- Proband\_split: Desglose por genes de las CNVs incluidas en la hoja 'Proband' con información detallada. Si una CNV no tiene ningún gen asociado, no aparece en este listado. Incluye anotación completa proporcionada por AnnotSV, como elementos reguladores cercanos, overlap, frameshift, ...
- Relatives: CNVs de familiares no presentes en el probando, con estructura similar a la hoja 'Proband'.
- Relatives\_split: Una hoja para cada familiar con sus CNVs desglosadas por gen (estructura similar a 'Proband\_split').
- Hojas de CNVs somáticas: Tumor Only, Tumor vs PON y Tumor vs Normal para cada muestra de tumor.

Las columnas de AnnotSV y ClassifyCNV (hojas 'Proband' y 'Relatives') están coloreadas atendiendo a los criterios del ACMG:

- Patogénica (P) (puntuación  $\geq 0.99$ ): rojo
- Probablemente patogénica (LP) (puntuación 0.90 a 0.98): naranja
- Variante de significado incierto (VUS) (puntuación 0.89 a -0.89): amarillo
- Probablemente benigna (LB) (puntuación -0.90 a -0.98) y benigna (B) (puntuación  $\leq -0.99$ ): sin colorear.

**Nota sobre CNVs somáticas:** La información de CNVs somáticas debe interpretarse con precaución debido a posibles limitaciones por el panel de normales empleado. El uso de un panel de normales no parafrinadas puede no ser la mejor aproximación, ya que para estudios de CNVs somáticas debería emplearse un panel de muestras tumorales embebidas en parafina, idealmente del mismo tipo de cáncer que la muestra analizada. Por lo tanto, la interpretación de estas CNVs queda a criterio de cada comité.

### 3.2. Implementación de los scripts

La implementación del algoritmo de CNVs se realiza mediante dos scripts de Python y uno de bash. El paso 1 (preprocesamiento) se ejecuta desde el script `cnv_preprocess.py`. La primera parte del paso 2 (priorización con la herramienta ClassifyCNV) se ejecuta desde el script de bash `run_classifycnv.sh`. El resto del paso 2, junto con el paso 3 (generación del informe) se ejecutan desde el script `cnv_annotation_reporting.py`. Todos reciben como argumento la ruta a la carpeta de análisis de una familia y se pueden ejecutar de forma automatizada desde el orquestador `run_family_cnv_sv.sh`.

## Script `cnv_preprocess.py`

Este script implementa el paso 1 del proceso de priorización de CNVs, que consiste en el parseo y filtrado de los archivos de entrada proporcionados por los nodos de secuenciación para generar los archivos intermedios necesarios para los pasos posteriores.

En primer lugar, crea la carpeta `CNV/INTERMEDIATES` para guardar los archivos intermedios generados y comprueba que están disponibles los archivos de CNVs germinales esperados para la familia en `CNV/INPUTS/` (véase sección 2.2). A continuación, procesa los archivos aplicando los criterios de filtrado descritos en la sección 3.1.

En las muestras de CNAG, combina las CNVs únicas de los dos archivos proporcionados (ventanas de 5,000 y 20,000 bp). Para ello, las CNVs detectadas en la ventana de 5 kbp se añaden a las de 20 kbp, eliminando solapamientos recíprocos ( $\geq 70\%$ ) para evitar duplicados. El campo `'CNV_window'` indica la ventana de detección para cada CNV. Por otra parte, los valores `'#'` o vacíos en las frecuencias internas que indican la ausencia de una variante en la cohorte de referencia se transforman en cero. Además, dado que CNAG calcula la frecuencia interna usando muestras de referencia de la ventana de 20 kbp, se añade una frecuencia interna adicional para la ventana de 5 kbp calculada con las 186 muestras de la cohorte de IMPaCT-Genómica (campo `'IMPaCT exact counts (5 kbp)'`). Como resultado de este proceso se generan varios archivos intermedios. Para el probando se guardan archivos en formato BED, TSV y pickle con las CNVs `'full'` parseadas y filtradas como `<SAMPLE>.CNVs.annotated_parsed.*`. Además, las CNVs `'split'` se guardan en un archivo pickle `<SAMPLE>.CNVs.annotated_parsed_split.pkl`. Para los familiares, se guardan los mismos archivos pero excluyendo las CNVs que solapen recíprocamente con el probando ( $\geq 70\%$ ), mientras que estas CNVs compartidas con el probando se guardan en un archivo pickle adicional `<family_id>.CNVs.relative_overlap_proband.pkl`. Los archivos BED contienen las posiciones cromosómicas de las CNVs filtradas y se emplean como entrada para la herramienta ClassifyCNV que se ejecuta en el siguiente paso.

El procesamiento de los archivos de somático se realiza posteriormente durante la etapa de anotación (paso 2.7).

## Script `run_classifycnv.sh`

Este script ejecuta la primera parte del paso 2 aplicando la herramienta ClassifyCNV para priorizar las CNVs filtradas del probando y familiares usando los archivos BED generados en el paso anterior. En la carpeta `INTERMEDIATES/ClassifyCNV/` se guardan para cada muestra un archivo con la clasificación de las CNVs (`<SAMPLE>_Scoresheet.txt`) y una carpeta con la salida completa de ClassifyCNV (`<SAMPLE>_ClassifyCNV_result/`).

## Script `cnv_annotation_reporting.py`

Este script completa el paso de priorización y genera el informe en formato Excel. Al iniciarse crea la carpeta `CNV/OUTPUTS/` para guardar los archivos generados y ejecuta secuencialmente los siguientes subpasos:

- Paso 2.1. Comparación de la priorización entre AnnotSV y ClassifyCNV. Como archivos de entrada se utilizan las CNVs `'full'` preprocesadas en el paso 1 `<SAMPLE>.CNVs.annotated_parsed.pkl` y el resultado de la priorización con ClassifyCNV `<SAMPLE>_Scoresheet.txt`. Para cada muestra, los archivos se combinan y se guarda un archivo con las CNVs del probando (`<family_id>_proband_priorization.pkl`) y otro con las únicas de los familiares (`<family_id>_relatives_priorization.pkl`).
- Paso 2.2. Anotación de las CNVs del probando compartidas con familiares (solapamiento recíproco  $\geq 70\%$ ) añadiendo información de genotipo y estado de cada familiar. Para ello, se utilizan las CNVs del probando guardadas en el paso 2.1 y se combina con las CNVs de familiares compartidas con el probando preprocesadas en el paso 1 (`<family_id>.CNVs.relative_overlap_proband.pkl`). El resultado se guarda en el archivo `<family_id>_proband_sharedcnvs.pkl`.
- Paso 2.3. Combinación de las CNVs únicas de los familiares incluyendo información fenotípica. Se utiliza el archivo de los familiares generado en el paso 2.1 y se guarda el archivo `<family_id>_relatives_mergedcnvs.pkl`.
- Paso 2.4. Anotación de genes relacionados con cáncer (lista de cáncer hereditario y base de datos COSMIC). No se guarda ningún archivo.
- Paso 2.5. Anotación de rutas y funciones de los genes afectados (Uniprot, KEGG y Reactome). No se guarda ningún archivo.
- Paso 2.6. Anotación con frecuencia poblacional usando la base de datos gnomAD (solapamiento recíproco  $\geq 70\%$ ). Se añaden estos campos con la información de gnomAD para probando y familiares:
  - gnomAD (int): Número de CNVs coincidentes
  - gnomAD\_ID (str | None): ID de la mejor coincidencia (mayor frecuencia poblacional y mayor longitud)
  - gnomAD\_freq (float | None): Frecuencia poblacional
  - gnomAD\_length (int | None): Longitud de la CNV Las CNVs únicas de familiares se guardan en el archivo final `<family_id>_relatives_cnvs_annotated.pkl`.
- Paso 2.7. Procesamiento de CNVs somáticas y anotación de las CNVs germinales del probando (solapamiento recíproco  $\geq 70\%$ ). En los archivos de somático, las CNVs se filtran por calidad (`FILTER = 'PASS'` y `QUAL  $\geq 30$` ) y se

anotadas con AnnotSV si no lo están. Excepto para CNAG que ya aplica el filtro 'PASS' y no proporciona el campo 'QUAL', por lo que no se aplica ningún filtro adicional. Se guarda un archivo con las CNVs germinales del probando anotadas `<family_id>_proband_tumour.pkl` y otro con las CNVs de somático de todas las muestras de tumor `<family_id>_family_tumours.pkl`.

- Paso 2.8. Anotación con SVs en el probando (solapamiento recíproco  $\geq 70\%$ ). Se guarda un archivo final con las CNVs del probando anotadas `<family_id>_proband_cnvs_annotated.pkl`.

Nota: Todos los solapamientos se calculan teniendo en cuenta que sean variantes del mismo tipo y que solapen recíprocamente al menos un 70%.

Como último paso del algoritmo, se genera el informe final en formato Excel `<family_id>_prioritized_CNVs.xlsx` en la carpeta `CNV/OUTPUTS/`. Se utilizan las CNVs 'full' anotadas de probando (hoja 'Proband') y familiares (hoja 'Relatives') con los archivos generados en los pasos 2.8 y 2.6, respectivamente. Para las hojas de CNVs 'split' se utilizan los archivos generados en el paso 1 (`<SAMPLE>.CNVs.annotated_parsed_split.pkl`) anotando los genes con la lista de genes asociados a cáncer hereditario (columna solicitada por el comité de mama). Para las hojas de somático se utiliza el archivo generado en el paso 2.7 (`<family_id>_family_tumours.pkl`). Si la familia no tiene muestras tumorales, el informe se genera sin los campos de somático en la hoja 'Proband' y sin las hojas de CNVs somáticas.

Al informe se añade un glosario con la descripción de cada hoja y campo para facilitar su interpretación, el cual se encuentra en la carpeta `glosarios/`. Además, se incluye un resumen de la familia y las variantes detectadas en el análisis (hoja 'Summary'), que se genera con la función `add_summary_sheet` importada del script `execution_summary_excel.py`.

## 4. Priorización de SVs

### 4.1. Descripción del proceso

El proceso de priorización de variantes estructurales (SVs) consiste en tres pasos principales:

1. Preprocesamiento
2. Priorización
3. Generación del informe en formato Excel

#### Paso 1. Preprocesamiento

En el primer paso, se realiza el parseo y filtrado de los archivos de entrada proporcionados por los nodos de secuenciación. Dependiendo del nodo, los archivos de entrada varían. Las SVs germinales, anotadas con AnnotSV por los nodos, se filtran de acuerdo a los siguientes criterios:

- Calidad mínima: se eliminan variantes con una calidad QUAL inferior a 30.
- Calidad por 'FILTER': se conservan variantes con valor 'PASS'. Para FPGMX, los archivos ya vienen filtrados por 'PASS' y no se incluyen este campo.
- Frecuencia interna exacta (campo 'Exact counts'): se eliminan variantes con un valor superior a 10.
- Filtro adicional para FPGMX: como el mismo archivo contiene CNVs y SVs, se seleccionan las SVs que son las que no tienen 'GAIN' o 'LOSS' en el campo 'SV\_type\_original'.

Los filtros se aplican sobre las SVs 'full' y 'split' comprobando que las mismas variantes pasan los filtros.

En CNAG, cuando una variante no se encuentra en la referencia usada para calcular frecuencias internas (exact, similar y other), se codifica como '#', por lo que se transforma a 0.

Tras el filtrado, para cada muestra se agrupan variantes que solapan recíprocamente ( $\geq 70\%$ ), seleccionando como variante representativa de cada grupo la que tiene mayor puntuación de AnnotSV y, en caso de empate, la de mayor longitud. Este paso es necesario ya que algunas SVs difieren solo en unas pocas posiciones.

En los archivos de somático, las SVs se filtran por calidad (FILTER = 'PASS' y QUAL  $\geq 30$ ) y se anotan con AnnotSV si no lo están.

#### Paso 2. Priorización

La priorización de SVs se basa en las recomendaciones de la ACMG para SVs germinales (Raca et al., 2023) usando la herramienta AnnotSV. La información detallada sobre la implementación de estos criterios en AnnotSV se encuentra en la documentación de la herramienta.

Además de la priorización, se anotan las variantes con la siguiente información:

- SVs del probando compartidas con familiares (solapamiento recíproco  $\geq 70\%$ ).
- Genes asociados: relacionados con cáncer (lista de cáncer hereditario y base de datos COSMIC), rutas/funciones (Uniprot, KEGG y Reactome).
- Frecuencia poblacional usando la base de datos gnomAD (solapamiento recíproco  $\geq 70\%$ ).
- Presencia en somático de las SVs del probando (solapamiento recíproco  $\geq 70\%$ ).
- Solapamiento con CNVs para el probando (solapamiento recíproco  $\geq 70\%$ ).

Finalmente, se combinan las SVs de los familiares que no están en el probando.

#### Paso 3. Generación del informe

Finalmente, se genera un informe en formato Excel con el nombre del ID de la familia seguido por 'prioritized\_SVs.xlsx' que incluye las siguientes hojas:

- Proband: SVs del probando ordenadas por puntuación de AnnotSV y, después, por longitud. La tabla recoge coordenadas y tipo de SV, clasificación AnnotSV, anotación de los genes asociados (incluyendo asociación a cáncer hereditario, COSMIC, OMIM y Uniprot, KEGG y Reactome), información familiar (genotipo, estado, sexo y breakpoints), presencia en tumor, frecuencia interna, gnomAD, coincidencia con otras SVs y solapamiento con CNVs.
- Proband\_split: Desglose por genes de las SVs del probando (hoja 'Proband') con información detallada. Si una SV no tiene ningún gen asociado, no aparece en este listado. Incluye anotación completa proporcionada por AnnotSV, como elementos reguladores cercanos, overlap, frameshift, ...
- Relatives: SVs de familiares no presentes en el probando, con estructura similar a la hoja 'Proband'.
- Relatives\_split: Una hoja para cada familiar con sus SVs desglosadas por gen (estructura similar a 'Proband\_split').
- Hojas con las variantes somáticas: Tumor Only, Tumor vs PON y Tumor vs Normal para cada muestra de tumor.

Las columnas de AnnotSV (hojas Proband y Relatives) están coloreadas atendiendo a los criterios del ACMG:

- Patogénica (P) (puntuación  $\geq 0.99$ ): rojo
- Probablemente patogénica (LP) (puntuación 0.90 a 0.98): naranja
- Variante de significado incierto (VUS) (puntuación 0.89 a -0.89): amarillo
- Probablemente benigna (LB) (puntuación -0.90 a -0.98) y benigna (B) (puntuación  $\leq -0.99$ ): sin colorear.

## 4.2. Implementación de los scripts

La implementación del algoritmo de SVs se realiza mediante el script de Python `sv_pipeline.py`, excepto la anotación de los archivos de somático con AnnotSV cuando no lo están, que se hace desde el script de bash `run_annotsv.sh`. Ambos reciben como argumento la ruta a la carpeta de análisis de una familia y se ejecutan de forma automatizada desde el orquestador `run_family_cnv_sv.sh`.

### Script `run_annotsv.sh`

Este script anota con AnnotSV los archivos de somático entregados por los nodos de secuenciación. Se ejecuta cuando hay archivos somáticos pendientes de anotar.

### Script `sv_pipeline.py`

Este script implementa los tres pasos del proceso de priorización de SVs: preprocesamiento (paso 1), priorización (paso 2) y generación del informe (paso 3). Al iniciarse crea las carpetas `SV/INTERMEDIATES` y `SV/OUTPUTS` para guardar los archivos generados.

En el paso 1, busca y valida los archivos germinales de entrada en `SV/INPUTS/` según el nodo (información detallada sobre los archivos de entrada en la sección 2.2).

A continuación, según el nodo se filtran estos archivos por calidad (`FILTER = 'PASS'` y `QUAL  $\geq 30$` ) y frecuencia interna (Illumina.exact.counts (CNAG) o Illumina\_DRAGEN.exact.counts (FPGMX y NASERTIC)  $< 10$ ). Los archivos de FPGMX ya están filtrados por 'PASS' y no se dispone de este campo. Además, para FPGMX hay un único archivo con CNVs y SVs, por lo que se aplica un filtro adicional para seleccionar solo las SVs, conservando aquellas que no tengan el valor 'GAIN' o 'LOSS' en el campo 'SV\_type\_original'. En CNAG, las CNVs que no se encuentran en la referencia usada para la frecuencia interna, tienen el valor '#', por lo que se cambia a 0.

Los filtros se aplican a todas las SVs y se valida la consistencia entre anotaciones full/split. Los archivos generados con las SVs 'full' procesadas se guardan en formato TSV (`<SAMPLE>.SVs.annotated_parsed.tsv`; SVs ordenadas por cromosoma e inicio) y pickle (`<SAMPLE>.SVs.annotated_parsed.pkl`). Además, las SVs 'split' se guardan en un archivo pickle (`<SAMPLE>.SVs.annotated_parsed_split.pkl`). Este proceso se realiza para cada integrante de una familia.

En el paso 2, el script ejecuta secuencialmente los subpasos de priorización y anotación:

- Paso 2.1. Filtrado de SVs solapantes del probando a partir del archivo con las SVs 'full' procesadas en el paso 1. Para ello, se selecciona la variante representativa (mayor puntuación AnnotSV y, en caso de empate, mayor longitud) y se registra el ID del resto de SVs. Con el resultado se genera el archivo `<family_id>_proband_svsvs_filtered.pkl`.
- Paso 2.2. Anotación de SVs del probando compartidas con familiares (solapamiento recíproco  $\geq 70\%$ ) y añade información de segregación/fenotipo. Por un lado, se guardan estas variantes anotadas en el archivo `<family_id>_proband_sharedsvsvs.pkl`, pero también se guardan las SVs de familiares no compartidas con el probando en el archivo `<family_id>_relatives_unique.pkl` para su posterior combinación en el paso 2.3.
- Paso 2.3. Combinación de SVs de los familiares no presentes en el probando añadiendo información de fenotipo. Se guarda el archivo `<family_id>_relatives_mergedsvsvs.pkl`.
- Paso 2.4. Filtrado de SVs solapantes en los familiares, seleccionando la variante representativa (mayor puntuación AnnotSV y, en caso de empate, mayor longitud). Se registra el ID del resto de SVs. Se guarda el archivo `<family_id>_relatives_svsvs_filtered.pkl`.
- Paso 2.5. Anotación de genes relacionados con cáncer (lista de genes de cáncer hereditario y COSMIC) en probando y familiares. No se guarda ningún archivo.
- Paso 2.6. Anotación de rutas y funciones de los genes afectados (Uniprot, KEGG y Reactome). No se guarda ningún archivo.
- Paso 2.7. Anotación con frecuencia poblacional usando la base de datos gnomAD (solapamiento recíproco  $\geq 70\%$ ). Se añaden estos campos con la información de gnomAD para probando y familiares:
  - gnomAD (int): Número de SVs coincidentes
  - gnomAD\_ID (str | None): ID de la mejor coincidencia (mayor frecuencia poblacional y mayor longitud)
  - gnomAD\_AC (int | None): Número de alelos
  - gnomAD\_AF (float | None): Frecuencia poblacional

- gnomAD\_FREQ\_HOMALT (int | None): Frecuencia de homocigotos alterados Las SVs de familiares se guardan en el archivo final <family\_id>\_relatives\_svs\_annotated.pkl.
- Paso 2.8. Procesamiento de SVs somáticas y anotación de las SVs germinales del probando (solapamiento recíproco  $\geq 70\%$ ). En los archivos de somático, las SVs se filtran por calidad (FILTER = 'PASS' y QUAL  $\geq 30$ ) y se anotan con AnnotSV si no lo están. Se guarda un archivo con las SVs germinales del probando anotadas <family\_id>\_<family\_id>\_proband\_tumour.pkl y otro con las SVs de somático de todas las muestras de tumor <family\_id>\_family\_tumours.pkl.
- Paso 2.9. Anotación con CNVs en el probando (solapamiento recíproco  $\geq 70\%$ ). Se guarda un archivo final con las SVs del probando anotadas <family\_id>\_<family\_id>\_proband\_svs\_annotated.pkl.

Nota: Todos los solapamientos se calculan teniendo en cuenta que sean variantes del mismo tipo y que solapen recíprocamente al menos un 70%.

En el paso 3, se genera el informe final en formato Excel <family\_id>\_prioritized\_SVs.xlsx en la carpeta SV/OUTPUTS/. Se utilizan las SVs 'full' anotadas de probando (hoja 'Proband') y familiares (hoja 'Relatives') con los archivos generados en los pasos 2.9 y 2.7, respectivamente. Para las hojas de SVs 'split' se utilizan los archivos generados en el paso 1 (<SAMPLE>.SVs.annotated\_parsed\_split.pkl) anotando los genes con la lista de genes asociados a cáncer hereditario (columna solicitada por el comité de mama). Para las hojas de somático se utiliza el archivo generado en el paso 2.8 (<family\_id>\_family\_tumours.pkl). Si la familia no tiene muestras tumorales, el informe se genera sin los campos de somático en la hoja 'Proband' y sin las hojas de SVs somáticas.

Al informe se añade un glosario con la descripción de cada hoja y campo para facilitar su interpretación, el cual se encuentra en la carpeta glosarios/. Además, se incluye un resumen de la familia y las variantes detectadas en el análisis (hoja 'Summary'), que se genera con la función add\_summary\_sheet importada del script execution\_summary\_excel.py.

## Nota sobre genotipo y número de copias

Para las muestras de ADN germinal, la información de genotipo (GT) y número de copias (CN) depende del nodo de secuenciación:

- **NASERTIC:** Proporciona el formato típico de genotipo en archivos generados por DRAGEN. Para CNVs, en la columna 'sample\_id' están los valores separados por ':' y en la columna 'FORMAT' se indica el orden. En este caso el formato es GT:SM:CN:BC:GC:CT:AC:PE, donde GT es el genotipo y CN es el número de copias estimado en esa región. Para SVs, está en la columna con el ID de la muestra (por ejemplo, '3832-3832-4impact-01') con el formato GT:FT:GQ:PL:PR:SR:SB:FS:VF, donde GT es el genotipo.
- **FPGMX:** El genotipo para CNVs y SVs está en la columna 'Zygosity'. El número de copias para CNVs se indica en la columna 'CopyNumber'.
- **CNAG:** Para CNVs, el número de copias se encuentra en la columna 'ControlFreeC\_CopyNumber' y el genotipo en la columna con el ID de la muestra (para IMPaCT-Genómica). Las muestras de VUSCan no tienen información de genotipo. Para SVs, el genotipo está en la columna con el ID de la muestra.

## 5. Arquitectura del flujo

### 5.1. Script principal (orquestador)

- `run_family_cnv_sv.sh`

### 5.2. Scripts llamados por el orquestador

- `run_annotsv.sh`
- `../CNV_PIPELINES/cnv_preprocess.py`
- `../CNV_PIPELINES/run_classifycnv.sh`
- `../CNV_PIPELINES/cnv_annotation_reporting.py`
- `../SV_PIPELINES/sv_pipeline.py`
- `preprocess_cnv_sv_vuscan.py`

## 6. Requisitos y dependencias

### 6.1. Sistema

- Linux/WSL
- Bash

### 6.2. Entornos Conda

- `annotsv_env`: Preprocesar y filtrar archivos somáticos VCF con `bcftools`, y después anotar con `AnnotSV`.
- `classifycnv_env`: Priorizar CNVs con `ClassifyCNV`.
- `pipeline`: Ejecutar scripts de Python de CNV/SV.

Todos los entornos se generan con los YAML del repositorio en la ruta `VUSCAN/envs/`.

### 6.3. Dependencias de rutas

- El orquestador usa rutas relativas entre carpetas del repositorio.
- Debe ejecutarse desde la carpeta `VUSCAN/general_scripts` para evitar errores de ruta relativa.

## 7. Manual de ejecución

### 7.1. Preparación del entorno de trabajo (solo la primera vez)

1. Se requiere sistema Linux o una máquina virtual (como WSL).

2. Instalar Conda y los entornos necesarios (ver sección 6.2).

```
# Instalar Conda
wget https://repo.anaconda.com/miniconda/Miniconda3-latest-Linux-x86_64.sh
bash Miniconda3-latest-Linux-x86_64.sh
source ~/.bashrc
conda install mamba -n base -c conda-forge

# Instalar entorno `annotsv_env`
conda env create -f ../envs/annotsv.yml -n annotsv_env
conda activate annotsv_env
git clone https://github.com/lgmgeo/AnnotSV.git
cd AnnotSV
chmod +x AnnotSV
make PREFIX=. install
make PREFIX=. install-human-annotation
conda deactivate

# Instalar entorno `classifycnv_env`
conda env create -f ../envs/classifycnv.yml -n classifycnv_env
conda activate classifycnv_env
mamba install git -c conda-forge
git clone http://github.com/Genotek/ClassifyCNV.git
cd ClassifyCNV/
chmod +x update_clingen.sh
./update_clingen.sh
# Ejemplo de uso para comprobar la instalación
python3 ClassifyCNV.py --infile YourCNVFile.bed --GenomeBuild {hg19,hg38}
ll ClassifyCNV_results/
rm -r ClassifyCNV_results/

# Instalar entorno `pipeline`
conda env create -f ../envs/pipeline.yml -n pipeline
conda activate pipeline
```

3. Clonar el repositorio de VUSCan desde GitHub y acceder a la carpeta `general_scripts`:

```
git clone <repository_url> ## https://github.com/estefaniahuergo/VUSCAN.git
cd VUSCAN/general_scripts
```

4. Crear carpeta del proyecto.

```
mkdir <BASEDIR>
# Donde <BASEDIR> es la ruta a la carpeta del proyecto, por ejemplo:
↪ ~/mnt/c/Users/bioinfor/Desktop/VUSCAN_PIPELINES/DATA/SAMPLES/VUSCan_families/.
```

5. Guardar los archivos necesarios (ver sección 2.1): - Archivo correspondencia muestras-fenotipo

```
cp <path_to_muestras_fenotipo.txt> <BASEDIR>/muestras_fenotipo.txt
```

- Archivos adicionales (COSMIC, lista genes cáncer hereditario, gnomAD, funciones Uniprot, glosario)

```

mkdir <BASEDIR>/cancer_genes <BASEDIR>/glosarios <BASEDIR>/gnomad <BASEDIR>/pathway_annotation_db
cp <path_to_cancer_hereditary_genes_file> <BASEDIR>/cancer_genes/lista_CH_genes.txt # Genes
↳ asociados a cáncer hereditario
cp <path_to_cosmic_file> <BASEDIR>/cancer_genes/tsg_og.tsv # Base de datos COSMIC
cp <path_to_gnomad_file> <BASEDIR>/gnomad/gnomad.v4.1.cnv.non_neuro_controls_filtered.tsv # Base
↳ de datos gnomAD para CNVs
cp <path_to_gnomad_file> <BASEDIR>/gnomad/gnomad.v4.1.sv.non_neuro_controls_final.tsv # Base de
↳ datos gnomAD para SVs
cp <path_to_uniprot_file> <BASEDIR>/pathway_annotation_db/uniprot.txt # Funciones Uniprot
cp <path_to_kegg_file> <BASEDIR>/pathway_annotation_db/kegg_pathways.tsv # Anotación rutas KEGG
cp <path_to_reactome_file> <BASEDIR>/pathway_annotation_db/Gene2Reactome.txt # Anotación rutas
↳ Reactome
cp <path_to_glossary_cnv_file> <BASEDIR>/glosarios/glosario_cnv.xlsx # Glosario de CNVs
cp <path_to_glossary_sv_file> <BASEDIR>/glosarios/glosario_sv.xlsx # Glosario de SVs

```

6. Modificar los scripts para que apunten a la carpeta de análisis y a los archivos necesarios (punto 5).

## 7.2. Preparación de los archivos de una familia

1. Crear una carpeta para guardar los archivos de las familias y otra carpeta para cada nodo si no existen.

```

mkdir <BASEDIR>/SAMPLES
mkdir <BASEDIR>/SAMPLES/<NODO>

```

2. Crear carpeta con el ID de la familia en la carpeta del nodo.

```

mkdir <WORKDIR>
# Donde <WORKDIR> es <BASEDIR>/SAMPLES/<NODO>/<FAMILY_ID>

```

3. Guardar dentro el archivo PED (revisar que la información del archivo es correcta).

```

cp <path_to_ped_file> <WORKDIR>

```

4. Crear los directorios para guardar los archivos de entrada según el nodo. Para CNAG y NASERTIC, las carpetas son CNV/INPUTS y SV/INPUTS, mientras que para FPGMX es una única carpeta INPUTS porque CNVs y SVs están en el mismo archivo.

```

mkdir <WORKDIR>/CNV/INPUTS <WORKDIR>/SV/INPUTS # CNAG y NASERTIC
mkdir <WORKDIR>/INPUTS # FPGMX

```

5. Guardar los archivos de germinal según el nodo.

```

# Para CNAG y NASERTIC:
cp <path_to_cnv_files> <WORKDIR>/CNV/INPUTS
cp <path_to_sv_files> <WORKDIR>/SV/INPUTS
# Para FPGMX
cp <path_to_cnv_files> <WORKDIR>/INPUTS

```

6. Crear las carpetas de somático y guardar los archivos de somático.

```

# CNAG y NASERTIC
mkdir <WORKDIR>/CNV/INPUTS/SOMATIC <WORKDIR>/SV/INPUTS/SOMATIC
cp <path_to_somatic_cnv_files> <WORKDIR>/CNV/INPUTS/SOMATIC
cp <path_to_somatic_sv_files> <WORKDIR>/SV/INPUTS/SOMATIC

```

```
# FPGMX
mkdir <WORKDIR>/INPUTS/SOMATIC_CNV <WORKDIR>/INPUTS/SOMATIC_SV
cp <path_to_somatic_cnv_sv_files> <WORKDIR>/INPUTS/SOMATIC_CNV
cp <path_to_somatic_cnv_sv_files> <WORKDIR>/INPUTS/SOMATIC_SV
```

7. Añadir la información de la familia en el archivo `muestras_fenotipo.txt` si no está. Esta información se puede encontrar en el Sharepoint de VUSCan.

### 7.3. Uso del orquestador

Uso del orquestador desde VUSCAN/general\_scripts mediante la línea de comandos:

```
run_family_cnv_sv.sh <NODO> <FAMILIA> [FAMILIA2 ...]
run_family_cnv_sv.sh <NODO> --all
```

Parámetros:

- NODO: nodo de secuenciación (FPGMX, NASERTIC, CNAG).
- FAMILIA: ID de la familia a analizar (identificador numérico). Se pueden indicar varias familias separadas por espacio.
- --all: analizar todas las familias en la carpeta del nodo.

Ejemplos de ejecución:

- Una familia:

```
run_family_cnv_sv.sh FPGMX 1042
```

- Varias familias con el listado de IDs:

```
run_family_cnv_sv.sh FPGMX 1042 1043 1044
```

- Todas las familias en la carpeta de un nodo:

```
run_family_cnv_sv.sh NASERTIC --all
```

Hay establecido un límite para ejecución en paralelo de 2 familias (MAX\_PARALLEL=2). Para ejecutar más familias a la vez, se puede modificar este parámetro en el script `run_family_cnv_sv.sh`.

### 7.4. Rutas de trabajo

- Ruta base dada al orquestador para la ejecución (<BASEDIR>):

```
/mnt/c/Users/bioinfor/Desktop/VUSCAN_PIPELINES/DATA/SAMPLES/VUSCan_families/<NODO>
```

- Carpeta de destino final de cada familia procesada:

```
<BASEDIR>/SAMPLES/<NODO>/PENDIENTES_SUBIR
```

- Para cada familia:
  - Carpeta de trabajo (): <BASEDIR>/SAMPLES/<NODO>/<FAMILIA>/
  - Ruta al archivo log: <WORKDIR>/<FAMILIA>\_family.log

Dado que el script usa rutas relativas para varios scripts, debe ejecutarse desde VUSCAN/general\_scripts para evitar errores de ruta relativa.

### 7.5. Flujo completo por pasos

#### Anotación somática (AnnotSV)

Comando:

```
conda run --no-capture-output -n annotsv_env bash run_annotsv.sh "$NODO" "$WORKDIR"
```

Ejecución según nodo:

- CNAG: No requiere anotación somática.
- FPGMX:

- Comprime archivos TSV de CNVs y SVs somáticos anotados, si no lo están.
- Procesa archivos VCF de CNVs y SVs sin anotar (<WORKDIR>/SOMATIC/\*.vcf.gz). Genera archivos filtrados por 'PASS', anotados con AnnotSV y comprimidos:
  - CNV TO: \*.filtered\_annotated.tsv.gz
  - SV TO: \*.sv.filtered\_annotated.tsv.gz
- NASERTIC: Procesa archivos de CNVs y SVs de somático sin anotar (<WORKDIR>/CNV/INPUTS/SOMATIC/\*.vcf.gz y <WORKDIR>/SV/INPUTS/SOMATIC/\*.vcf.gz). Genera archivos filtrados por 'PASS', anotados con AnnotSV y comprimidos:
  - CNV TO: <SAMPLE>.CNVs.TO.annotated.PASSfiltered.tsv.gz
  - CNV PON: <SAMPLE>.CNVs.PON.annotated.PASSfiltered.tsv.gz
  - SV TO: <SAMPLE>.SVs.TO.annotated.PASSfiltered.tsv.gz

## Algoritmo CNVs - Paso 1: Preprocesado de CNVs

Comando:

```
conda run --no-capture-output -n pipeline python3 ../CNV_PIPELINE/cnv_preprocess.py "$WORKDIR"
```

Como resultado, genera archivos TSV, BED y pickle en <WORKDIR>/CNV/INTERMEDIATES/:

- Archivos generados por muestra (probandando y familiares; para familiares solo se incluyen variantes que no están en el probando):
  - .CNVs.annotated\_parsed.tsv
  - .CNVs.annotated\_parsed.bed
  - .CNVs.annotated\_parsed.pkl
  - .CNVs.annotated\_parsed\_split.pkl
- Archivo adicional para los familiares:
  - <FAMILIA>.CNVs.relative\_overlap\_proband.pkl (CNVs de familiares compartidas con el probando)

## Algoritmo CNVs - Paso 2.0: Priorización con ClassifyCNV

Comando:

```
conda run --no-capture-output -n classifycnv_env bash ../CNV_PIPELINE/run_classifycnv.sh "$WORKDIR"
```

Entrada esperada:

- Archivos BED para probando y familiares en la ruta <WORKDIR>/CNV/INTERMEDIATES/{sample\_id}.bed

Como resultado, genera en <WORKDIR>/CNV/INTERMEDIATES/ClassifyCNV/:

- <SAMPLE>\_Scoresheet.txt: para cada muestra genera un archivo con la priorización de ClassifyCNV
- <SAMPLE>\_ClassifyCNV\_result/: carpeta con la salida completa de ClassifyCNV para la familia

## Algoritmo CNVs - Pasos 2 y 3: Anotación de CNVs y generación del informe

Comando:

```
conda run --no-capture-output -n pipeline python3 ../CNV_PIPELINE/cnv_annotation_reporting.py  
↪ "$WORKDIR"
```

Como resultado, genera archivos pickles de priorización/anotación y un informe final Excel en <WORKDIR>/CNV/OUTPUTS/:

- Archivos intermedios en formato pickle:
  - <FAMILIA>\_proband\_priorization.pkl
  - <FAMILIA>\_relative\_priorization.pkl (si hay familiares)
  - <FAMILIA>\_proband\_sharedcnvs.pkl
  - <FAMILIA>\_relative\_mergedcnvs.pkl (si hay familiares)
  - <FAMILIA>\_proband\_tumour.pkl
  - <FAMILIA>\_family\_tumours.pkl (si hay muestras tumorales)
  - <FAMILIA>\_proband\_cnvs\_annotated.pkl
  - <FAMILIA>\_relative\_cnvs\_annotated.pkl (si hay familiares)
- Informe final:
  - <FAMILIA>\_prioritized\_CNVs.xlsx

## Algoritmo SVs - Pasos 1-3: Pipeline completo

Comando:

```
conda run --no-capture-output -n pipeline python3 ../SV_PIPELINE/sv_pipeline.py "$WORKDIR"
```

Resultado:

- Genera archivos intermedios por muestra en <WORKDIR>/SV/INTERMEDIATES/.
- Genera archivos de priorización/anotación e informe final Excel en <WORKDIR>/SV/OUTPUTS/.

Archivos intermedios en SV/INTERMEDIATES (por muestra):

- <SAMPLE>.SVs.annotated\_parsed.tsv
- <SAMPLE>.SVs.annotated\_parsed.pkl
- <SAMPLE>.SVs.annotated\_parsed\_split.pkl

Pickles de salida en SV/OUTPUTS (familia):

- <FAMILIA>\_proband\_svsvs\_filtered.pkl
- <FAMILIA>\_proband\_sharedsvsvs.pkl
- <FAMILIA>\_relatives\_unique.pkl (si hay familiares)
- <FAMILIA>\_relatives\_mergedsvsvs.pkl (si hay familiares)
- <FAMILIA>\_relatives\_svsvs\_filtered.pkl (si hay familiares)
- <FAMILIA>\_proband\_tumour.pkl
- <FAMILIA>\_family\_tumours.pkl (si hay muestras tumorales)
- <FAMILIA>\_proband\_svsvs\_annotated.pkl
- <FAMILIA>\_relatives\_svsvs\_annotated.pkl (si hay familiares)

Reporte final SV:

- <FAMILIA>\_prioritized\_SVs.xlsx

## Paso adicional - Comprobación de la ejecución y ruta de salida

La ejecución del orquestador genera un archivo de log por familia en <WORKDIR>/<FAMILIA>\_family.log con salida duplicada en terminal. Se recomienda revisar este archivo para comprobar que la ejecución se ha realizado correctamente y que no hay errores o resultados inesperados.

La carpeta de análisis de cada familia procesada se mueve a <BASEDIR>/SAMPLES/<NODO>/PENDIENTES\_SUBIR. Se aconseja revisar los informes de CNVs y SVs generados en la carpeta OUTPUTS antes de subirlos al SharePoint del proyecto. Una vez subidos también se aconseja mover la carpeta de la familia a otra carpeta, por ejemplo <BASEDIR>/SAMPLES/<NODO>/PROCESADAS para tener un control de las familias pendientes de analizar, las procesadas y las entregadas.

## Anexo A. Archivos generados y estructura de salida

### A.1. Estructura de carpetas

```
<BASEDIR>/
|-- cancer_genes/
|-- glosarios/
|-- gnomad/
|-- pathway_annotation_db/
`-- SAMPLES/
    |-- <NODO>/
        |-- <FAMILIA>/ # Carpeta de trabajo de la familia (<WORKDIR>)
            |-- CNV/
                |-- INPUTS/
                |-- INTERMEDIATES/
                |-- ClassifyCNV/
                |-- OUTPUTS/
            |-- SV/
                |-- INPUTS/
                |-- INTERMEDIATES/
                |-- OUTPUTS/
        |-- PENDIENTES_SUBIR/
```

### A.2. Archivos de entrada

Los archivos de NASERTIC se descargan desde el servidor Aspera. Para las familias de VUSCan están dentro de la carpeta VUSCAN/ organizados en carpetas específicas según el tipo de análisis:

- El archivo de CNVs de Tumor vs PON está en `tumor_only_analysis > CNV_PON_tumor_VUSCAN`.
- **ADN germinal (WGS):** Los archivos de CNVs y SVs están en la carpeta de análisis de WGS para cada batch de muestras dentro de `AnnotSV/`, con la extensión `.updated.tsv` que son los que incluyen la frecuencia interna.
- **Tumor vs Normal (WES):** Los archivos anotados de CNVs y SVs están en las carpetas de análisis de WES para cada batch de muestras dentro de `AnnotSV/`.
- **Tumor Only (WES):** Los archivos de CNVs y SVs requieren filtrado por 'PASS' y anotación con `AnnotSV`, y cada uno se encuentra en una carpeta diferente:
  - CNVs: Están en la carpeta `Somatic_analysis_WES` con nombre `*.cnv.vcf`.
  - SVs: Están en la carpeta `tumor_only_analysis/{sample_id}_tumor_only` con nombre `*.sv.vcf`.
- **Tumor vs PON (WES):** El archivo de CNVs está en la carpeta `tumor_only_analysis > CNV_PON_tumor_VUSCAN`.

### A.3. Archivos generados

#### A.3.1. Logging

Log por familia con salida duplicada en terminal y archivo log en `<WORKDIR>/<FAMILIA>_family.log`.

#### A.3.2. CNV/INTERMEDIATES

Esta tabla consolida los pasos y archivos generados en todo el flujo, unificando la información que antes aparecía en la sección 7.5 con las tablas específicas de salida de los apartados A.3.2 a A.3.7.

| Carpeta de salida                       | Archivo generado                                                                                                    | Contenido                                                                            |
|-----------------------------------------|---------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|
| Anotación somática                      |                                                                                                                     |                                                                                      |
| CNAG: Los archivos se entregan anotados |                                                                                                                     |                                                                                      |
| FPGMX (SVs): INPUTS/SOMATIC/            | <code>&lt;SAMPLE&gt;.filtered_annotated.tsv.gz</code> y<br><code>&lt;SAMPLE&gt;.sv.filtered_annotated.tsv.gz</code> | SVs y CNVs filtradas por<br>PASS, anotadas con<br><code>AnnotSV</code> y comprimidas |

| Carpeta de salida                                 | Archivo generado                                                                                                                                                                                             | Contenido                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       |
|---------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| NASERTIC: SV/INPUTS/SOMATIC/                      | <SAMPLE>.SVs.TO.annotated.PASSfiltered.SVs.gz<br>en NASERTIC;<br><SAMPLE>.filtered_annotated.tsv.gz y<br><SAMPLE>.sv.filtered_annotated.tsv.gz<br>en FPGMX                                                   | SVs y CNVs somáticas<br>filtradas por PASS, anotadas<br>con AnnotSV y<br>comprimidas según el nodo                                                                                                                                                                                                                                                                                                                                                                                                              |
| CNV - Preprocesado (paso 1)<br>CNV/INTERMEDIATES/ | <SAMPLE>.CNVs.annotated_parsed.tsv,<br><SAMPLE>.CNVs.annotated_parsed.bed,<br><SAMPLE>.CNVs.annotated_parsed.pkl,<br><SAMPLE>.CNVs.annotated_parsed_split.pkl<br><FAMILIA>.CNVs.relative_overlap_proband.pkl | CNVs germinales<br>parseadas, filtradas y<br>preparadas para<br>priorización                                                                                                                                                                                                                                                                                                                                                                                                                                    |
| CNV - ClassifyCNV                                 | CNV/INTERMEDIATES/ClassifyCNV/                                                                                                                                                                               | <SAMPLE>_Scoresheet.txt,<br><SAMPLE>_ClassifyCNV_result/                                                                                                                                                                                                                                                                                                                                                                                                                                                        |
| CNV - Anotación e informe                         | CNV/OUTPUTS/                                                                                                                                                                                                 | <FAMILIA>_proband_priorization.pkl,<br><FAMILIA>_relative_priorization.pkl,<br><FAMILIA>_proband_sharedcnvs.pkl,<br><FAMILIA>_relative_mergedcnvs.pkl,<br><FAMILIA>_proband_tumour.pkl,<br><FAMILIA>_family_tumours.pkl,<br><FAMILIA>_proband_cnvs_annotated.pkl,<br><FAMILIA>_relative_cnvs_annotated.pkl,<br><FAMILIA>_prioritized_CNVs.xlsx                                                                                                                                                                  |
| SV - Pipeline completo                            | SV/INTERMEDIATES/ y SV/OUTPUTS/                                                                                                                                                                              | <SAMPLE>.SVs.annotated_parsed.tsv,<br><SAMPLE>.SVs.annotated_parsed.pkl,<br><SAMPLE>.SVs.annotated_parsed_split.pkl,<br><FAMILIA>_proband_svsvs_filtered.pkl,<br><FAMILIA>_proband_sharedsvsvs.pkl,<br><FAMILIA>_relative_unique.pkl,<br><FAMILIA>_relative_mergedsvsvs.pkl,<br><FAMILIA>_relative_svsvs_filtered.pkl,<br><FAMILIA>_proband_tumour.pkl,<br><FAMILIA>_family_tumours.pkl,<br><FAMILIA>_proband_svsvs_annotated.pkl,<br><FAMILIA>_relative_svsvs_annotated.pkl,<br><FAMILIA>_prioritized_SVs.xlsx |

Archivos preprocesados de CNVs germinales para probando y familiares en <WORKDIR>/CNV/INTERMEDIATES/:

| Nombre archivo                              | Descripción                                                              | Relación                       |
|---------------------------------------------|--------------------------------------------------------------------------|--------------------------------|
| <SAMPLE>.CNVs.annotated_parsed.tsv          | Archivo TSV con CNVs ‘full’                                              | Probando (todas las variantes) |
| Familiares (no compartidas con el probando) |                                                                          |                                |
| <SAMPLE>.CNVs.annotated_parsed.bed          | Archivo BED con CNVs ‘full’ para ClassifyCNV                             | Probandos                      |
| <SAMPLE>.CNVs.annotated_parsed.pkl          | Archivo pickle con CNVs ‘full’                                           | Probandos                      |
| <SAMPLE>.CNVs.annotated_parsed_split.pkl    | Archivo pickle con CNV ‘split’                                           | Probandos                      |
| <FAMILIA>.CNVs.relative_overlap_proband.pkl | Archivo pickle con CNVs ‘full’ de familiares compartidas con el probando |                                |

### A.3.3. CNV/INTERMEDIATES/ClassifyCNV

| Nombre archivo               | Descripción                                    |
|------------------------------|------------------------------------------------|
| <SAMPLE>_Scoresheet.txt      | Resultado de priorización con ClassifyCNV      |
| <SAMPLE>_ClassifyCNV_result/ | Carpeta de resultados completos de ClassifyCNV |

### A.3.4. CNV/OUTPUTS

| Nombre archivo                         | Descripción                     |
|----------------------------------------|---------------------------------|
| <FAMILIA>_proband_priorization.pkl     | Priorización del probando       |
| <FAMILIA>_relatives_priorization.pkl   | Priorización de familiares      |
| <FAMILIA>_proband_sharedcnvs.pkl       | CNV compartidas en probando     |
| <FAMILIA>_relatives_mergedcnvs.pkl     | CNV familiares fusionadas       |
| <FAMILIA>_proband_tumour.pkl           | Probando anotado con somático   |
| <FAMILIA>_family_tumours.pkl           | Variantes de tumores familiares |
| <FAMILIA>_proband_cnvs_annotated.pkl   | CNV probando final anotado      |
| <FAMILIA>_relatives_cnvs_annotated.pkl | CNV familiares anotadas         |
| <FAMILIA>_prioritized_CNVs.xlsx        | Informe final de CNV            |

### A.3.5. SV/INTERMEDIATES

| Patrón de archivo                       | Descripción        |
|-----------------------------------------|--------------------|
| <SAMPLE>.SVs.annotated_parsed.tsv       | Tabla SV parseada  |
| <SAMPLE>.SVs.annotated_parsed.pkl       | SV full en pickle  |
| <SAMPLE>.SVs.annotated_parsed_split.pkl | SV split en pickle |

### A.3.6. SV/OUTPUTS

| Patrón de archivo                     | Descripción                       |
|---------------------------------------|-----------------------------------|
| <FAMILIA>_proband_svs_filtered.pkl    | SV probando filtradas             |
| <FAMILIA>_proband_sharedsvs.pkl       | SV probando compartidas           |
| <FAMILIA>_relatives_unique.pkl        | SV únicas de familiares           |
| <FAMILIA>_relatives_mergedsvs.pkl     | SV fusionadas de familiares       |
| <FAMILIA>_relatives_svs_filtered.pkl  | SV familiares filtradas           |
| <FAMILIA>_proband_tumour.pkl          | Probando anotado con SV somáticas |
| <FAMILIA>_family_tumours.pkl          | Somático familiar                 |
| <FAMILIA>_proband_svs_annotated.pkl   | SV probando anotadas finales      |
| <FAMILIA>_relatives_svs_annotated.pkl | SV familiares anotadas            |
| <FAMILIA>_prioritized_SVs.xlsx        | Informe final de SV               |

### A.3.7. Movimiento final de carpeta familiar

- Origen: <BASEDIR>/SAMPLES/<NODO>/<FAMILIA>
- Destino: <BASEDIR>/SAMPLES/<NODO>/PENDIENTES\_SUBIR/<FAMILIA>
- Si existe destino: <FAMILIA>\_YYYYmmdd\_HHMMSS